

✓ Problema 1

1.- Modelo de regresión lineal simple:

X: Horas de estudio

Y: Calificación obtenida

$$Y_i = B_0 + B_1 X_i + E_i$$

B_0 es el intercepto ya sea calificación esperada cuando las horas son 0

B_1 es la pendiente ya sea el incremento promedio en la calificación por cada hora adicional de estudio

Por último la E_i es el error aleatorio

- Métrica de error

Suma de los Errores Cuadrados (SSE):

$$SSE = \sum (Y_i - \hat{Y}_i)^2$$

Esta métrica penaliza más los errores grandes y permite obtener una solución matemática óptima.

3.- Método de optimización

Mínimos Cuadrados

$$B_1 = \text{Cov}(X, Y) / \text{Var}(X)$$

$$B_0 = \bar{Y} - B_1 \bar{X}$$

Calcula la pendiente como la razón entre la covarianza y la varianza de X lo que puedo decir que eso minimiza el error total.

Descripción del comportamiento de la población

2. Enfoque académico / estadístico

Puedo decir que el modelo muestra que existe una relación lineal entre las horas de estudio y la calificación.

Coefficiente B_1 : representa el cambio promedio esperado en la calif por cada hora adicional. Si su p-value es menor a 0.05 entonces existe evidencia estadística suficiente para afirmar que la relación es significativa

Esto se debe a que entre más horas estudia un alumno mejor calif tiende a conseguir u obtener.

No significa que estudiar garantice una calif exacta pero sí que existe una tendencia clara que es que estudiar más por así decir generalmente ayuda a mejorar el resultado final.

Comparación de p-value del coeficiente β_1 y p-value del estadístico F:

Esto se debe a que es una regresión lineal simple. El estadístico F del modelo evalúa la misma hipótesis que el estadístico t del coef B_1 .

Matemáticamente:

$$F = t^2$$

$$H_0: B_1 = 0$$

Ya con esta explicación puedo decir que hacen o generan el mismo p-value ya que esto solo ocurre cuando hay un único predictor.

3.- Estudio de predicción

Unos cambios que realizaría yo creo que podrían ser:

- mostrar gráficas claras y no solo inferencia.
- Detectar y manejar outliers
- Automatizar el cálculo de métricas

Dividir los datos en entrenamiento y prueba ya sea 70%-30%.

Estos cambios permitirían mostrar que tan bien predice el modelo en datos nuevos y no solo en los datos de training o entrenamiento.

Métricas para evaluar calidad del modelo

Yo usaría RMSE la cual su fórmula es raíz cuadrada de $1/n + \sum (Y_i - \hat{Y}_i)^2$, porque penaliza grandes errores.

Otra sería MAE = $1/n \cdot \sum |Y_i - \hat{Y}_i|$, porque es fácil de interpretar.

Para finalizar seria R^2 porque mide que proporción de la variabilidad es explicada por el modelo.

Un modelo no lineal mejora la predicción?

Un modelo de segundo orden podría tal vez mejorar un poco si existe efecto de rendimientos decrecientes.

Modelo polinomial de tercer orden no es recomendable porque tiene alto riesgo sobreajuste y sus comportamientos no son realistas.

Modelo regresión spline podría también mejorar si la relación cambia a pendiente en diferentes rangos de horas.

KNN con $k = 3$, probable sobreajuste y muy sensible al ruido.

KNN con $K = 300$, igualmente sobreajuste y demasiado suavizado ya eso hace que pierda estructura.

```
import numpy as np
import pandas as pd
from scipy import stats

# Cambia la ruta si es necesario
data = pd.read_csv("P1 Datos1(2).csv")

# Asegúrate que las columnas se llamen exactamente así:
# horas (X) y calificación (Y)
X = data.iloc[:, 0].values # Horas de estudio
Y = data.iloc[:, 1].values # Calificación

n = len(X)

X_mean = np.mean(X)
Y_mean = np.mean(Y)

beta1 = np.sum((X - X_mean)*(Y - Y_mean)) / np.sum((X - X_mean)**2)
beta0 = Y_mean - beta1 * X_mean

Y_hat = beta0 + beta1 * X

SSE = np.sum((Y - Y_hat)**2)
MSE = SSE / (n - 2)
RMSE = np.sqrt(MSE)

SST = np.sum((Y - Y_mean)**2)
R2 = 1 - (SSE / SST)

SE_beta1 = np.sqrt(MSE / np.sum((X - X_mean)**2))

t_stat = beta1 / SE_beta1

p_value_t = 2 * (1 - stats.t.cdf(abs(t_stat), df=n-2))
SSR = SST - SSE
F_stat = (SSR / 1) / (SSE / (n - 2))

p_value_F = 1 - stats.f.cdf(F_stat, 1, n-2)

print("=== RESULTADOS REGRESIÓN LINEAL SIMPLE ===\n")
print(f"Beta0 (Intercepto): {beta0}")
print(f"Beta1 (Pendiente): {beta1}\n")

print(f"SSE: {SSE}")
print(f"MSE: {MSE}")
print(f"RMSE: {RMSE}")
print(f"R^2: {R2}\n")

print(f"t-stat beta1: {t_stat}")
print(f"p-value (t): {p_value_t}\n")

print(f"F-stat: {F_stat}")
print(f"p-value (F): {p_value_F}")
```

=== RESULTADOS REGRESIÓN LINEAL SIMPLE ===

Beta0 (Intercepto): 48.07005444261577
Beta1 (Pendiente): 4.257566455755204

```

SSE: 36399.39696370549
MSE: 73.09115856165761
RMSE: 8.549336732265118
R^2: 0.7015346576331934

t-stat beta1: 34.21308865733037
p-value (t): 0.0

F-stat: 1170.535435474348
p-value (F): 1.1102230246251565e-16

```

Problema 2

Multicolinealidad:

ft2: tamaño en ft cuadrados m2: tamaño en m cuadrados

Estas 2 variables representan exactamente la misma info en distintas unidades y eso hace que exista colinealidad entre ambas.

Llegue a esta conclusion ya que son conversaciones directas y matematicamente una es combinacion lineal exacta de la otra y esto puede generar o genera mas bien inflacion en err estandares, problemas de interpretacion, etc.

- Tamaño de muestra pequeño

Como dice en las instrucciones nada mas hay 50 observaciones. Con varias variables explicativas, el modelo puede sobreajustar o no generalizar correctamente ya que pues en si son pocas observaciones.

- Posible variable irrelevante

Variable fibra tiene p - value = 0.938 y t = -0.079 y esto indica que no es estadisticamente significativa.

- Posible mala seleccion de variables

Nada mas se usó solo 2 variables del sistema lo cual no sabemos cuales ni bajo que criterio y por esto puede haber: Omision de variable relevante y mala especificacion del modelo.

Ideas de como los resolveria

Multicolinealidad: simplemente eliminar unas de las variables y conservar metros cuadrados yua que es la que mas se usa en México. Esto mejoraria la estabilidad del modelo. Es la mejor solucion porque ambas contienen exacatamente la misma info.

- Solucion a variable irrelevante:

p - value = 0.938 > 0.05 no hay evidencia estadistica que afecte el precio. algunas opciones serian eliminarla del modelo y mantenerla solo si existe justificación para simplificar el modelo.

- Solucion al tamaño de muestra:

No se puede modificar el tamaño y lo que haria seria validacion cruzada, separar datos en training y test y analizar estabilidad de coeficientes.

- Solucion a posible mala especificacion:

Revisaria si se omitio baños, si existe interaccion entre variables y si la relacion es estrictamente lineal. Compararia modelos usando R al cuadrado ajustado, AIC y BIC.

Comentario sobre la calidad del modelo mostrado

- Metricas relevantes de la tabla: R al cuadrado = 0.977 R al cuadrado ajustado = 0.976 Estadisitco - F = 969.3 Prob F = 2.50e-38

Calidad global: R al cuadrado = 0.977 indica que el modelo explica 97,7% de la variabilidad del precio lo cual es muy alto. La prueba F tiene p-value 0 eso da que el modelo globalmente es significativo y pues en conclusion el modelo es fuerte por asi decir.

- Relevancia individual de variables

m2:

coef = 0.9267 p-value. = 0.000

Muy significativo lo cual tiene fuerte impacto en el precio.

fibra:

coef = -0.3345 p-value = 0.938

No es significativo y no aporta por asi decr a la evidencia estadistica.

Falta alguna metrica?

Si, RMSE, VIF (colinealidad) y Division entrenamiento/prueba porque R al cuadrado no garantiza buena prediccion futura.

Interpretacion de coeficientes

Modelo estimado:

precio = $533.8875 + 0.9267(m \text{ al cuadrado}) - 0.3345(\text{fibra})$, trabajando con un 95% de confianza.

Intercepto:

Si una casa tuviera 0 m cuadrados y sin fibra el precio seria 533.89, interpretacion matematica y no practica.

Coefficiente de m al cuadrado:

Por cada metro cuadrado adicional el precio aumenta en prom 0.9267 manteniendo constante la variable fibra. El intervalo de confianza 95% es [0.884,0.970] y como no incluye el 0 el efecto es significativo.

Coefficiente fibra:

Manteniendo constante el tamaño, tener fibra cambia el precio en -0.3345 pero no es estadisticamente significativo, el intervalo [-8.898, 8.229] incluye el 0 y no podemos concluir que tenga efecto real.

Problema 3

Combinar: Eliminacion hacia atras y criterio rapido tipo fast forward.

En lugar de comenar sin variables e ir agregando podemos comenzar con todas las variables y vamos eliminando asi rapido las menos relevantes usando un criterio eficiente por asi decir.

- Idea general del metodo:

Comenzar con las 50 variables, ajustaar un modelo completo, evaluar relevancia de cada variable, elminar rapido la peor variable segun un criterio estadistico, etc. El metodo busca ser computacionalmente mas eficiente que backward clásico.

- Criterio de eliminacion:

En este podemos usar: p-value mayor a 0.05, o mayor incremento en AIC/BIC o menor contribucion absoluta al modelo. Para hacer esto rapido se puede eliminar directamente la peor variable en cada iteracion sin reevaluar combinacion multiples.

- Pseudocodigo

Inicio

- 1.- Cargar datos desde "Pq Datos3.csv" Leer matriz X (50 variables). Leer vector y (variable objetivo). n: numero de observaciones. p: 50.
- 2.- Definir: alpha: 0.05. Variables seleccionadas: {1,2,3,...,50}. Mejorar: Verdadero.
- 3.- Ajustar modelo completo: Modelo: Regresionlineal(X[Variables Seleccionadas], y).
- 4.- Mientras mejorar sea verdadero hacer: Obtener p-values de cada variables en el modelo actual. Encontrar: j: indice con mayor p-value. Si $p\text{-value}(j) > \alpha$ entonces: Eliminar j de Variables Seleccionadas. Ajustar nuevo modelo con las variables restantes. Sino: Mejorar: Falso. Fin mientras.
- 5.- Devolver Variables Seleccionadas.

Fin.

- Version mas rapida con AIC

Puede ser como:

- 4.- En cada iteracion: Para cada variable j en Variables Seleccionadas: Calcular AIC sin variable j. Elminar la variable cuya eliminacion reduzca mas el AIC. Si ningun AIC mejora: detener.

Condiciones de paro posibles: Todas las variables restantes tienen $p\text{-value} < \alpha$, AIC no mejora, se alcanza lmiite de iteraciones, etc.

- Generaria la misam solucion que seleccion rapida hacia adelante

No, seleccion hacia adelante parte sin variables, solo agrega variables relevantes que individualmente mejoran el modelo.

Selecccion hacia atras: inicia con todas y evalua variables entre todas las demas.

Por correlaciones entre variables, interacciones ocultas y supresion estadistica puede pasar que una variable no sea significativa sola pero si sea importante cuando otras no estan presnetes.

