

PREGUNTA 1

Lo que propongo hacer durante la semana

Para responder ambas preguntas (¿Cuántos grupos naturales existen? y ¿son estables?), propongo la siguiente estrategia:

1. Preprocesamiento del dataset: Estandarizar las variables (z-score) para que ninguna dimensión domine por escala, y aplicar PCA para visualización y reducción de ruido, igual que en el tercer parcial.

2.- Determinar el número óptimo de clusters: No asumiré que son 4 grupos desde el inicio. Usaré métodos objetivos:

- Elbow method sobre inercia (K-means, $k = 2 \dots 10$)
- Silhouette score para medir que tan bien separados están los clusters
- Dendograma de clustering jerárquico como evidencia adicional

Esto me permitirá ver si $k = 4$ está respaldado por los datos o si el paper de tu asesor usó un dataset con características diferentes.

3.- Aplicar múltiples métodos de clustering: Para evaluar estabilidad, correría al menos 3 métodos:

- K-means ($k = 4$ y k óptimo)
- Clustering Jerárquico Aglomerativo (linkage: ward, complete, average)
- DBSCAN (como contraste density-based, sin asumir k)

4.- Evaluar estabilidad entre métodos: Compararé los resultados entre métodos usando el Adjusted Rand Index (ARI): si 2 métodos distintos producen particiones muy similares (ARI cercano a 1), los grupos son estables. Si el ARI es bajo, los grupos dependen fuertemente del método.

5.- Entregable de la reunión

- Tabla comparativa de métricas (silhouette, ARI entre pares de métodos)
- Visualización PCA con colores por cluster para cada método
- Conclusión clara: número recomendado de grupos y nivel de estabilidad

PSEUDOCÓDIGO:

--- PREPROCESAMIENTO ---

```
datos    ← cargar_dataset()
datos_std ← estandarizar(datos)      # z-score por columna
datos_pca ← aplicar_PCA(datos_std, n=2) # para visualización
```

--- SELECCIÓN DE k ---

para k en $[2..10]$:

```

modelo_km ← KMeans(k)
etiquetas_km ← modelo_km.ajustar(datos_std)
inercias[k] ← modelo_km.inercia
silhouettes[k]← calcular_silhouette(datos_std, etiquetas_km)

k_optimo ← identificar_codo(inercias) y validar con max(silhouettes)

dendrograma ← clustering_jerarquico(datos_std, linkage='ward')
graficar_dendrograma(dendrograma)

# --- CLUSTERING CON MÚLTIPLES MÉTODOS ---
eti_kmeans ← KMeans(k=k_optimo).ajustar(datos_std)
eti_km4 ← KMeans(k=4).ajustar(datos_std) # comparar con paper
eti_ward ← Jerarquico(k=k_optimo, linkage='ward').ajustar(datos_std)
eti_comp ← Jerarquico(k=k_optimo, linkage='complete').ajustar(datos_std)
eti_dbscan ← DBSCAN(eps=auto, min_samples=5).ajustar(datos_std)


# --- EVALUACIÓN DE ESTABILIDAD ---
ARI_km_ward ← adjusted_rand_index(eti_kmeans, eti_ward)
ARI_km_comp ← adjusted_rand_index(eti_kmeans, eti_comp)
ARI_ward_comp ← adjusted_rand_index(eti_ward, eti_comp)

# --- VISUALIZACIÓN Y REPORTE ---
para cada (método, etiquetas):
    graficar_PCA(datos_pca, etiquetas, título=método)

imprimir tabla: [método, silhouette, ARI vs KMeans]
concluir_estabilidad(ARIs) # estable si ARI > 0.75 entre pares

```

Diagrama de flujo



Esa sería mi propuesta completa para la semana. En resumen no asumir $k = 4$ de entrada sino validarlo con datos, correr al menos 3 familias de algoritmos para tener comparación real y usar ARI como métrica objetiva de estabilidad. Si los ARIs entre pares de métodos son altos (>0.75), le diré al asesor que los grupos son robustos, si son bajos, le explicaré que la estructura del dataset es ambigua y que $k = 4$ podría ser específico del método que usó el paper.

PREGUNTA 2

Resumen del trabajo del equipo anterior

El equipo importó un dataset real de imágenes médicas con 1,000 pacientes y 500 características numéricas por paciente, con 2 clases desbalanceadas (80% control, 20% enfermedad). Luego aplicaron PCA sin especificar número de componentes para graficar la varianza explicada por cada componente. Después tomaron los primeros 3 componentes de PCA, dividieron en train/test, entrenaron una regresión logística y reportaron accuracy, matriz de confusión y reporte de clasificación. Finalmente extrajeron los loadings absolutos del PC1 para identificar las 10 features más influyentes en la clasificación.

Comentarios al asesor

Lo que está mal:

- **No hubo preprocesamiento de los datos.** Antes de cualquier análisis se debió estandarizar (z-score) las 500 features, PCA es sensible a la escala, sin estandarización, las variables con mayor varianza dominan artificialmente los componentes. Planeamos agregarlo justo antes de aplicar PCA.
- **El número de componentes para la regresión se eligió arbitrariamente.** Usaron `X_pca[:, 1:4]` (componentes 2, 3 y 4, no 1, 2 y 3 el índice empieza en 0), lo que además es un error de indexación. La selección debió basarse en la varianza acumulada explicada (p. ej. 95%), no en un número fijo elegido sin criterio visible.
- **El accuracy del 84% es engañoso dado el desbalance de clases.** Con 80/20 de distribución, un clasificador que predice siempre la clase mayoritaria ya obtendría 80%. El equipo concluye “el modelo es bueno” basándose solo en accuracy, ignorando que el recall de la clase enferma es apenas 0.37 — a lo que voy es que el modelo falla en detectar 63% de los pacientes enfermos, lo cual en contexto médico es crítico. La métrica relevante aquí es el recall de la clase positiva y el F1 de esa clase (0.47), no el accuracy global.
- **Las “variables más importantes” están mal interpretadas.** Identificar features con alto loading en PC1 no equivale a identificar las variables más importantes para la clasificación. PC1 es el componente de mayor varianza, no necesariamente el más discriminativo entre clases. Para identificar variables relevantes para

clasificación se debería usar los loadings ponderados por el coeficiente de regresión de cada componente, o bien métodos directos como permutation importance.

Lo que sobra:

- La gráfica de varianza explicada por componente (imagen c) se generó pero nunca se usó para tomar ninguna decisión. Si no se va a usar para elegir el número de componentes, no aporta nada al flujo de trabajo.

Lo que falta:

- **Validación cruzada:** Un solo split train/test con random_state fijo no garantiza que los resultados sean estables. Se debe usar k-fold cross-validation.
- **Manejo del desbalance de clases.** No se aplicó ninguna estrategia: ni oversampling (SMOTE), ni undersampling, ni ajuste de class_weight = 'balanced' en la regresión logística. Planeemos agregarlo antes de entrenar el modelo.
- **Justificación del modelo.** No se exploró si la regresión logística es adecuada para este problema; al menos debería compararse contra un segundo clasificador (p. ej., SVM o Random Forest sobre los componentes PCA).
- **- Reproducibilidad.** Aunque el código usa random_state en algunos puntos, no hay semilla global (np.random.seed) ni documentación del entorno. Planeamos agregar ambos al inicio del notebook.

PREGUNTA 3

Metodología

Para interpretar los clusters se calcularon estadísticos descriptivos (media) de las variables continuas – edad, presión arterial en reposo, colesterol, frecuencia cardiaca máxima, depresión ST, número de vasos coloreados y número de vasos estrechados – separados por cluster. Para las variables categoricas (sexo, FBS, angina por ejercicio, tipo de dolor, ECG en reposo, pendiente ST, resultado Thallium) se calcularon tablas de proporciones por cluster. La significancia estadística de cada variable se evaluó formalmente: test de Mann-Whitney U para variables continuas y chi-cuadrado de Pearson para categóricas, con umbral $\alpha = 0.05$. Esto permitió distinguir que diferencias entre clusters son estadísticamente relevantes y cuales pueden hacer ruido.

Hallazgos relevantes

Las 3 variables con diferencias estadísticamente significativas entre clusters son el colesterol ($p < 0.001$), el número de vasos coloreados por fluoroscopia ($p = 0.003$) y el número de vasos con estrechamiento $\geq 50\%$ ($p = 0.021$). El cluster 1 presenta un colesterol sérico promedio notablemente más alto (284 mg/dL vs. 214 mg/dL en el Cluster 0), supera el umbral de riesgo cardiovascular de 240 mg/dL, mientras que el Cluster 0 se mantiene en rango borderline. El cluster 1 también muestra mayor carga de enfermedad arterial: más vasos coloreados (0.84 vs. 0.53 en promedio) y una distribución de num desplazada hacia valores más altos – solo el 46% de sus pacientes num = 0 (ningún vaso estrechado), frente

al 61% en el Cluster 0. En cuanto al ECG en reposo, el Cluster 1 tiene mayor proporción de hipertrofia ventricular probable o definitiva (57% vs. 42%, $p = 0.023$), lo que refuerza la mayor carga cardiovascular de ese grupo. Las demás variables (edad, presión arterial, frecuencia cardiaca, pendiente ST, resultado Thallium, tipo de dolor, sexo y FBS) no mostraron diferencias significativas entre clusters. En síntesis, el Cluster 1 agrupa pacientes con mayor riesgo cardiovascular, caracterizado por hiperlipidemia severa, más vasos comprometidos y mayor prevalencia de hipertrofia ventricular, mientras que el Cluster 0 representa un perfil de menor riesgo, con niveles lipídicos y compromiso arterial moderados.

Código nada más para mostrar:

```
import pandas as pd
import numpy as np
from scipy import stats

# — 1. CARGAR DATOS


---



df = pd.read_csv('P3.3 Interpretación.csv')

print("=" * 60)
print("ANÁLISIS DE INTERPRETACIÓN DE CLUSTERS — ENFERMEDAD CARDÍACA")
print("=" * 60)
print(f"\nTotal de pacientes : {len(df)}")
print(f"Cluster 0           : {(df['cluster'] == 0).sum()} pacientes")
print(f"Cluster 1           : {(df['cluster'] == 1).sum()} pacientes")

# — 2. VARIABLES DE INTERÉS


---



vars_continuas = ['age', 'trestbps', 'chol', 'thalach', 'oldpeak',
                  'ca', 'num']
vars_binarias = ['sex', 'fbs', 'exang']
vars_categoricas = ['cp', 'restecg', 'slope', 'thal']

c0 = df[df['cluster'] == 0]
c1 = df[df['cluster'] == 1]

# — 3. ESTADÍSTICOS DESCRIPTIVOS — VARIABLES CONTINUAS


---



print("\n" + "-" * 60)
print("MEDIAS POR CLUSTER — VARIABLES CONTINUAS")
print("-" * 60)

etiquetas = {
    'age'      : 'Edad (años)',
```

```

'trestbps' : 'Presión arterial en reposo (mmHg)',
'chol'      : 'Colesterol sérico (mg/dL)',
'thalach'   : 'Frecuencia cardíaca máxima',
'oldpeak'   : 'Depresión onda ST',
'ca'        : 'Vasos coloreados (fluoroscopia)',
'num'       : 'Vasos con estrechamiento ≥50%',
}

resumen_continuas =
df.groupby('cluster')[vars_continuas].mean().round(2)
print(resumen_continuas.rename(columns=etiquetas).T.to_string())

# — 4. PROPORCIONES — VARIABLES BINARIAS


---



print("\n" + "-" * 60)
print("PROPORCIONES POR CLUSTER — VARIABLES BINARIAS (valor = 1)")
print("-" * 60)

etiquetas_bin = {
    'sex' : 'Hombre',
    'fbs' : 'Azúcar en ayuno > 120 mg/dL',
    'exang': 'Angina inducida por ejercicio',
}

for col, etq in etiquetas_bin.items():
    p0 = c0[col].mean()
    p1 = c1[col].mean()
    print(f" {etq:<35} Cluster 0: {p0:.1%} Cluster 1: {p1:.1%}")

# — 5. DISTRIBUCIÓN — VARIABLES CATEGÓRICAS


---



print("\n" + "-" * 60)
print("DISTRIBUCIÓN POR CLUSTER — VARIABLES CATEGÓRICAS (proporciones)")
print("-" * 60)

for col in vars_categoricas:
    print(f"\n {col.upper()}")
    tabla = pd.crosstab(df['cluster'], df[col],
normalize='index').round(3)
    print(tabla.to_string())

```

— 6. PRUEBAS ESTADÍSTICAS

```
print("\n" + "-" * 60)
print("SIGNIFICANCIA ESTADÍSTICA")
print("-" * 60)

def simbolo_p(p):
    if p < 0.001: return "***"
    if p < 0.01:  return "**"
    if p < 0.05:  return "*"
    return "ns"

print("\n Variables continuas – Mann-Whitney U")
print(f" {'Variable':<35} {'p-valor':>10} {'Sig':>5}")
for col in vars_continuas:
    stat, p = stats.mannwhitneyu(c0[col].dropna(), c1[col].dropna())
    print(f" {etiquetas[col]:<35} {p:>10.4f} {simbolo_p(p):>5}")

print("\n Variables categóricas/binarias – Chi-cuadrado")
print(f" {'Variable':<35} {'p-valor':>10} {'Sig':>5}")
for col in vars_binarias + vars_categoricas:
    tabla = pd.crosstab(df['cluster'], df[col])
    chi2, p, dof, _ = stats.chi2_contingency(tabla)
    nombre = etiquetas_bin.get(col, col)
    print(f" {nombre:<35} {p:>10.4f} {simbolo_p(p):>5}")

print("\n Leyenda: *** p<0.001  ** p<0.01  * p<0.05  ns = no
significativo")

# — 7. DISTRIBUCIÓN DETALLADA DE num


---



print("\n" + "-" * 60)
print("DISTRIBUCIÓN DETALLADA – num (vasos con estrechamiento ≥50%)")
print("-" * 60)
tabla_num = pd.crosstab(df['cluster'], df['num'],
normalize='index').round(3)
print(tabla_num.to_string())

print("\n" + "=" * 60)
print("FIN DEL ANÁLISIS")
print("=" * 60)
```

Resultados del código

ANÁLISIS DE INTERPRETACIÓN DE CLUSTERS – ENFERMEDAD CARDÍACA

Total de pacientes : 297
 Cluster 0 : 156 pacientes
 Cluster 1 : 141 pacientes

MEDIAS POR CLUSTER – VARIABLES CONTINUAS

cluster	0	1
Edad (años)	53.55	55.64
Presión arterial en reposo (mmHg)	130.85	132.63
Colesterol sérico (mg/dL)	214.26	283.96
Frecuencia cardíaca máxima	150.96	148.10
Depresión onda ST	1.06	1.05
Vasos coloreados (fluoroscopia)	0.53	0.84
Vasos con estrechamiento $\geq 50\%$	0.82	1.09

PROPORCIONES POR CLUSTER – VARIABLES BINARIAS (valor = 1)

Hombre	Cluster 0: 71.8%	Cluster 1: 63.1%
Azúcar en ayuno > 120 mg/dL	Cluster 0: 14.7%	Cluster 1: 14.2%
Angina inducida por ejercicio	Cluster 0: 29.5%	Cluster 1: 36.2%

DISTRIBUCIÓN POR CLUSTER – VARIABLES CATEGÓRICAS (proporciones)

CP

cp	1	2	3	4
cluster				
0	0.109	0.16	0.301	0.429
1	0.043	0.17	0.255	0.532

RESTECG

restecg	0	1	2
cluster			
0	0.571	0.013	0.417
1	0.411	0.014	0.574

SLOPE

slope	1	2	3
cluster			
0	0.468	0.455	0.077
1	0.468	0.468	0.064

THAL

thal	3	6	7
cluster			
0	0.558	0.071	0.372
1	0.546	0.050	0.404

SIGNIFICANCIA ESTADÍSTICA

Variables continuas – Mann-Whitney U

Variable	p-valor	Sig
Edad (años)	0.0760	ns
Presión arterial en reposo (mmHg)	0.6324	ns
Colesterol sérico (mg/dL)	0.0000	***
Frecuencia cardíaca máxima	0.2751	ns
Depresión onda ST	0.9468	ns
Vasos coloreados (fluoroscopia)	0.0033	**
Vasos con estrechamiento $\geq 50\%$	0.0209	*

Variables categóricas/binarias – Chi-cuadrado

Variable	p-valor	Sig
Hombre	0.1411	ns
Azúcar en ayuno > 120 mg/dL	1.0000	ns
Angina inducida por ejercicio	0.2703	ns
cp	0.0917	ns
restecg	0.0229	*
slope	0.9019	ns
thal	0.6867	ns

Leyenda: *** $p < 0.001$ ** $p < 0.01$ * $p < 0.05$ ns = no significativo

DISTRIBUCIÓN DETALLADA – num (vasos con estrechamiento $\geq 50\%$)

num	0	1	2	3	4
-----	---	---	---	---	---