

UNIVERSIDAD DE MONTERREY
ESCUELA DE INGENIERÍA Y TECNOLOGÍAS

Ingeniería en Tecnologías Computacionales

Inteligencia Artificial



Examen Parcial 2

Diego Emilio Muñiz Ramirez 621784

Profesor: Antonio Martínez Torteya

San Pedro Garza García, 23 de marzo del 2026

“Doy mi palabra de que he realizado esta actividad con integridad académica”

Pregunta 1:

Se muestra el diagrama de una red neuronal.

- a) **Las primeras y últimas conexiones no coinciden con las capas densas típicamente utilizadas, ¿a qué me refiero con esto?**

En una capa densa normalmente cada neurona está conectada con todas las de la siguiente capa y pues esas conexiones tienen pesos que se aprenden durante el entrenamiento. Lo que pasa aquí es que las flechas de entrada y salida son conexiones 1 a 1, con esto me refiero que cada flecha de entrada va directo a una sola neurona y cada neurona de salida produce un solo valor. Esas conexiones no tienen pesos entrenables, solo pasan el dato, por eso no son capas densas como tal pues.

- b) **Indica la cantidad de parámetros que se necesitarían estimar para entrenar esta red, detallando el número por capa, y el porqué de dicho número. Presta mucha atención a las conexiones; insisto, las primeras y últimas conexiones no forman capas densas.**

Capa	Pesos	Sesgos	Total
Entrada(4) -> Oculta1(5)	$4 \cdot 5 = 20$	5	25
Oculta1(5) -> Oculta2(5)	$5 \cdot 5 = 25$	5	30
Oculta2(5) -> Salida(4)	$5 \cdot 4 = 20$	4	24
Total			79

Las flechas de entrada y salida no cuentan porque no tienen pesos de test o entrenables.

c) A partir de la arquitectura mostrada, explica y justifica si crees que esta arquitectura está diseñada para trabajar con imágenes.

No, primero porque solo tiene 4 entradas y cualquier imagen tiene muchísimos más píxeles. Segundo porque pues las redes para imágenes usan capas convolucionales que aprovechan la estructura espacial de los píxeles y esta red es solo un MLP sencillo. Esta red está diseñada para datos tabulares con 4 variables de entrada, no para imágenes.

Pregunta 3:

A continuación se muestra pseudocódigo que describe un algoritmo no revisado en clase.

¿A qué algoritmo(s) de los vistos en clase se parece? Indica claramente por qué y en qué se parecen.

Este algoritmo, tal y como se describe, ¿para qué tipo de problemas puede ser utilizado (clasificación, regresión, ambos, ninguno)?, ¿por qué? Si solo puede ser utilizado para un tipo de problema, indica qué modificaciones se tendrían que hacer para que pueda ser utilizado para el otro tipo de problema.

```
Entrada:
- Datos de entrenamiento D
- Datos de prueba P
- Número de modelos M
- Tipo de modelo base
Salida:
- Predicción en P

Método:
1. Inicializa un peso igual para cada punto de datos en D.
2. Para m = 1 hasta M hacer:
    a. Si m es impar:
        i. Crea una muestra seleccionando con reemplazo de D usando los pesos actuales.
        ii. Entrena un modelo en la muestra.
        iii. Actualiza los pesos de los puntos de datos en D para enfatizar los puntos mal clasificados.
    b. Si m es par:
        i. Crea una muestra seleccionando con reemplazo de D ignorando los pesos actuales.
        ii. Entrena un modelo en la muestra.
3. Combina todos los modelos M en un conjunto:
    a. Para una entrada dada p, la predicción del conjunto es la mediana de los modelos M.
```

a) ¿A qué algoritmo se parece?

Creo yo que se parece a una mezcla entre AdaBoost y Bagging. Cuando m es impar, crea muestras usando los pesos actuales y actualiza esos pesos dándole más importancia a los puntos mal clasificados, que es exactamente lo que hace AdaBoost. Cuando m es par, crea muestras con reemplazo ignorando los pesos, que es lo que hace Bagging. Al final combina todo con la mediana que es típico de los métodos de ensamble.

b) Para clasificación, regresión o ambos?

Bueno tal como está sirve para regresión, porque la predicción final es la mediana de todos los modelos, lo cual tiene sentido cuando la salida es un número continuo. Para clasificación no tendría sentido usar la mediana, ahí lo normal sería usar la moda.

Entonces para adaptarlo a clasificación solo habría que cambiar ese paso al final de mediana a votación mayoritaria.

Pregunta 4:

Con respecto a los árboles de decisión, responde las siguientes preguntas:

- Se sabe que los árboles de decisión, si no se les pone algún tipo de límite, tienden a generar resultados con un sobreajuste excesivo, ¿por qué? Apoya tu explicación con la imagen de un árbol que crece sin restricciones. En la imagen debe quedar completamente evidente que el árbol creció sin restricciones. La imagen puede ser dibujada a mano, con herramientas digitales, y/o con IA generativa.
- Para la imagen que se muestra, indica al menos dos posibles restricciones específicas que se le hayan definido al modelo para restringir su crecimiento (por ejemplo, si indicas que la cantidad de algo se restringió, especifica el número).





Imagen generada:



a) ¿Porque generan sobreajuste sin restricciones?

Cuando un árbol crece sin límites va haciendo divisiones hasta clasificar perfectamente cada punto del conjunto de entrenamiento. Esto significa que el árbol termina memorizando los datos en lugar de aprender un patrón general. Cuando llegan datos nuevos que no vio antes, falla porque las reglas que aprendió son demasiado específicas para esos puntos exactos. básicamente aprende el ruido de los datos, no el patrón real.

En la imagen se puede ver un ejemplo de árbol sin restricciones: llega a tener hojas con $n=1$, o sea una hoja por cada dato individual, con profundidad = 4, 16 hojas y $\text{min_samples_leaf} = 1$.

b) Restricciones observadas en la gráfica

1.- $\text{max_depth} = 3$: Se observa máximo 3 niveles de divisiones anidadas en la gráfica, lo que indica que se limitó la profundidad de árbol a 3.

2.- $\text{min_samples_leaf} = 5$: Las regiones de la gráfica contienen varios puntos dentro (no solo 1), lo que sugiere que se exige un mínimo de aproximadamente 5 muestras por hoja antes de permitir una división.


Pregunta 5:

Las siguientes imágenes se generaron tras haber obtenido un modelo de linear discriminant analysis usando la función `LinearDiscriminantAnalysis` de `sklearn`, así como los métodos `fit` y `transform`, entre otros. La base de datos utilizada cuenta con 150 observaciones, 40 variables de entrada, y una variable de salida cualitativa de 3 clases.

¿Los colores de la gráfica de densidad corresponden con los de la gráfica de dispersión? Es decir, ¿la curva azul de la primera gráfica tiene una relación directa con los puntos azules de la segunda gráfica?, ¿por qué?

¿Qué discriminante tiene mayor poder predictivo, LD1 o LD2?, ¿por qué?

En las gráficas solo se hace referencia a LD1 y a LD2, ¿es posible que en este ejemplo existan LD3 y LD4 también, pero que simplemente no se haya deseado graficarlas?, ¿por qué?



a) ¿Los colores de densidad corresponden con los de dispersión?

Si corresponden, en LDA cada clase se proyecta sobre el discriminante LD1 y eso genera una distribución. La curva verde de la gráfica de densidad corresponden a los puntos verdes de la dispersión, la naranja a los naranjas y la azul a los azules claramente. Tienen sentido juntas porque las 2 gráficas están mostrando lo mismo pero de diferente forma: una como distribución y otra como puntos en 2D.

b) ¿LD1 o LD2 tienen mayor poder predictivo?

LD1 tiene un mayor poder predictivo. LDA siempre construye los discriminantes ordenados de mayor a menor separación entre clases, entonces LD1 por definición es el que más separa. En la gráfica de densidad se ve claramente que las 3 clases están bastante separadas sobre LD1, con picos y en posiciones distintas. LD2 ayuda un poco más pero ya contribuye menos.

c) ¿Pueden existir LD3 y LD4?

No, el número máximo de discriminantes lineales en LDA está dado por $\min(p, K-1)$, donde p es el número de variables de entrada y K el número de clases. En este caso $p = 40$ variables y $K = 3$ clases, por lo que el máximo es $\min(40, 2) = 2$. Por eso solo existen LD1 y LD2; no es que no se quisieron graficar, es que matemáticamente no pueden existir más discriminantes.

Pregunta 6:

Indica un escenario del mundo real en que un modelo de regresión logística podría aplicarse. Asume que para dicho escenario se tiene una base de datos con 150 variables y 100 observaciones; la base ya se limpió (no hay huecos, multicolinealidad, valores erróneos, etc.).

En tu modelo, una variable cuantitativa tiene un coeficiente de 2.3 y una variable cualitativa de 2 clases tiene un coeficiente de 1.6, ambas tienen un p-value significativo. Indica, dentro del contexto del escenario que mencionaste, un ejemplo de lo que podrían estar midiendo dichas variables, así como la interpretación que darías a dichos resultados con respecto a la respuesta del sistema, asegurando que tu interpretación sea lo más fácilmente comprendida por una persona sin conocimientos del área (la explicación debe incluir cantidades específicas).

Cuando trabajamos con regresión lineal múltiple se mencionó el tema de regularización, específicamente de Lasso. Dicha metodología implicaba que, en vez de optimizar el RSS, se optimizara una función que incluía al RSS y un término de penalización. Dicha estrategia también puede aplicarse dentro del esquema de regresión logística. Para este escenario en particular, considerando tanto el área de aplicación como la base de datos con que se cuenta, ¿sería útil seguir dicha metodología?, ¿por qué? Independientemente de tu respuesta, indica claramente la función que se trataría de optimizar para emular la estrategia de Lasso en regresión logística.

Escenario: Predicción de si un paciente tiene diabetes, 150 variables clínicas, 100 pacientes, salida = tiene diabetes (si = 1 / no = 0).

a) Interpretación de coeficientes

- **Variable cuantitativa con coeficiente 2.3:** puede ser el nivel de glucosa en sangre. Significa que por cada unidad que suba la glucosa, los odds de tener diabetes se multiplican por $e^{2.3} = 10$. O sea, glucosa más alta aumenta bastante la probabilidad de diabetes. El p-value significativo nos dice que esta relación no es casualidad.
- **Variable cualitativa con coeficiente 1.6:** puede ser si el paciente tiene antecedentes familiares de diabetes (si/no). Tener antecedentes multiplica los odds por $e^{1.6} = 5$ comparado con no tenerlos. También es significativo, o sea sí importa en el modelo.

b) ¿Sería útil Lasso aquí?

Sería muy útil porque tenemos más variables (150) que observaciones las cuales son (100), lo cual es una situación donde es muy fácil sobreajustar. Lasso penaliza los coeficientes y manda a cero los de las variables que no aportan haciendo selección automática de variables.

La función que se optimizar sería:

$$\min_{\beta} \left[-\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)] + \lambda \sum_{j=1}^p |\beta_j| \right]$$

El primer término es la log-verosimilitud negativa (el equivalente al RSS PERO para regresión logística) y el segundo es la penalización L1 de Lasso. Lambda controla qué tan fuerte se penaliza.

Nota: Varias respuestas fueron apoyadas con apoyo de herramienta de inteligencia artificial (Claude, Anthropic).